

Seurat Guided Clustering Tutorial

Hendra Bunyamin

Setup the Seurat Object

Dalam tutorial ini, kita akan menganalisis kumpulan data Sel Mononuklear Darah Perifer (*Peripheral Blood Mononuclear Cells*, PBMC) yang tersedia secara gratis dari 10X Genomics. Terdapat 2.700 sel tunggal yang telah di-sequence dengan menggunakan Illumina NextSeq 500.

Kita mulai dengan membaca data. Fungsi `Read10X()` membaca hasil keluaran dari pipeline cellranger milik 10X, dan mengembalikan matriks jumlah (*count matrix*) UMI (Unique Molecular Identifier). Nilai-nilai dalam matriks ini mewakili jumlah molekul untuk setiap fitur (misalnya gen; baris) yang terdeteksi di setiap sel (kolom). Perlu dicatat bahwa versi cellranger yang lebih baru kini juga menghasilkan output dalam format file h5, yang dapat dibaca menggunakan fungsi `Read10X_h5()` di Seurat.

Selanjutnya, kita menggunakan *count matrix* untuk membuat objek **Seurat**. Objek ini berfungsi sebagai wadah yang menyimpan data (seperti *count matrix*) dan hasil analisis (seperti PCA atau hasil pengelompokan) untuk dataset data sel tunggal. Misalnya, di Seurat v5, *count matrix* disimpan di `pbmc[["RNA"]]$counts`.

```
library(dplyr)
library(Seurat)
library(patchwork)
```

```
# Load dataset PBMC
pbmc.data <- Read10X(data.dir = "datasets/filtered_gene_bc_matrices/hg19/")

# Initialize the Seurat object with the raw (non-normalized data).
pbmc <- CreateSeuratObject(counts = pbmc.data, project = "pbmc3k",
                           min.cells = 3, min.features = 200)
pbmc
```

An object of class Seurat
13714 features across 2700 samples within 1 assay
Active assay: RNA (13714 features, 0 variable features)
1 layer present: counts

Seperti apakah bentuk *count matrix*?

```
# Mari kita perhatikan beberapa gen pada 30 sel pertama  
pbmc.data[c("CD3D", "TCL1A", "MS4A1"), 1:30]
```

3 x 30 sparse Matrix of class "dgCMatrix"

```
CD3D  4 . 10 . . 1 2 3 1 . . 2 7 1 . . 1 3 . 2  3 . . . . . 3 4 1 5  
TCL1A . . . . . . . 1 . . . . . . . . . . 1 . . . . . . .  
MS4A1 . 6 . . . . . . 1 1 1 . . . . . . . . 36 1 2 . . 2 . . . .
```

Nilai . pada matriks menunjukkan 0 (tidak ada molekul yang terdeteksi). Karena kebanyakan nilai dalam sebuah matriks scRNA-seq adalah 0, Seurat menggunakan representasi sparse-matrix sebisa mungkin. Penggunaan sparse-matrix menghemat penggunaan memori dan mempercepat proses untuk Drop-seq/inDrop/10x data.

```
dense.size <- object.size(as.matrix(pbmc.data))  
dense.size
```

709591472 bytes

```
sparse.size <- object.size(pbmc.data)  
sparse.size
```

29905192 bytes

```
dense.size / sparse.size
```

23.7 bytes

Alur kerja prapemrosesan standar

Langkah-langkah di bawah ini mencakup alur kerja prapemrosesan standar untuk data scRNA-seq di Seurat. Langkah-langkah ini mencakup pemilihan dan penyaringan sel berdasarkan metrik kontrol kualitas (*quality control*, QC), normalisasi dan penskalaan (*scaling*) data, serta deteksi fitur yang sangat bervariasi.

Quality control (QC) dan pemilihan sel untuk analisis lebih lanjut


Seurat memungkinkan Anda untuk dengan mudah menjelajahi metrik QC dan menyaring sel berdasarkan kriteria apa pun yang ditentukan pengguna. Beberapa metrik QC yang umum digunakan oleh komunitas antara lain

- Jumlah gen unik yang terdeteksi di setiap sel.
 - Sel berkualitas rendah atau *droplet* kosong seringkali hanya mengandung sedikit gen.
 - Pasangan atau kelompok sel dapat menunjukkan jumlah gen yang sangat tinggi.
- Demikian pula, jumlah total molekul yang terdeteksi di dalam sel (berkorelasi erat dengan gen-gen unik)
- Persentase urutan (*reads*) yang terpetakan ke genom mitokondria.
 - Sel-sel berkualitas rendah atau yang sekarat sering kali menunjukkan kontaminasi mitokondria yang luas
 - Kami menghitung metrik QC mitokondria menggunakan fungsi `PercentageFeatureSet()`, yang menghitung persentase hitungan yang berasal dari sekumpulan fitur
 - Kami menggunakan himpunan semua gen yang diawali dengan MT- sebagai himpunan gen mitokondria

```
# The [[ operator can add columns to object metadata. This is a great place to stash QC stat
pbmc[["percent.mt"]] <- PercentageFeatureSet(pbmc, pattern = "^MT-")
```

Kita coba visualisasi hubungan antara `nCount_RNA` dan `nFeature_RNA`.

```
FeatureScatter(pbmc, feature1 = "nCount_RNA", feature2 = "nFeature_RNA")
```



Di manakah metrik QC disimpan di Seurat?

- Jumlah gen unik dan total molekul secara otomatis dihitung selama pemanggilan fungsi `CreateSeuratObject()`
 - Anda dapat menemukannya tersimpan di metadata dari objeknya.

```
# Tunjukkan metrik QC untuk 5 sel yang pertama
head(pbmc@meta.data, 5)
```

	orig.ident	nCount_RNA	nFeature_RNA	percent.mt
AAACATACAACCAC-1	pbmc3k	2419	779	3.0177759
AAACATTGAGCTAC-1	pbmc3k	4903	1352	3.7935958
AAACATTGATCAGC-1	pbmc3k	3147	1129	0.8897363
AAACCGTGCTTCCG-1	pbmc3k	2639	960	1.7430845
AAACCGTGATGCG-1	pbmc3k	980	521	1.2244898

Pada contoh di bawah ini, kita visualisasikan metrik QC, dan menggunakannya untuk menyaring sel-sel.

- Kita *drop* sel-sel yang mempunyai jumlah fitur unik di atas 2500 atau kurang dari 200 atau kita *keep* jumlah fitur unik yang $\Rightarrow 200 < \text{jumlah fitur unik} < 2500$.

- Kita *drop* sel-sel yang mempunyai jumlah mitokondria $> 5\%$. Sel-sel dengan jumlah mitokondria $> 5\%$ diindikasikan merupakan sel yang sekarat atau stress. Lebih lanjut, sel-sel dengan jumlah mitokondria $> 5\%$ biasanya sel dengan jumlah gen sedikit dan merupakan sel-sel yang tertangkap dengan buruk atau tidak maksimal dari platform droplets seperti 10X Genomics.

Mari kita visualisasikan metrik QC dalam plot biola.

```
# hello
# #| fig-width: 9
# #| fig-asp: 0.618

# Visualisasikan metrik QC sebagai plot biola
VlnPlot(pbmc, features = c("nFeature_RNA", "nCount_RNA", "percent.mt"),
        ncol = 3)
```

